

→ *seance 7 : 17 - 05 - 2021*

Chapitre 3 : Analyse en composantes principales ACP

→ on a un tableau :

⇒ tableau rectangulaire X de J variables quantitatives mesurées sur I individus : voir

x_i^j : la valeur de la variable j mesurée sur l'individu i

avec $i = 1, 2, \dots, I$ et $j = 1, 2, \dots, J$

- L'individu $\underline{x}_i = (x_i^1, x_i^2, \dots, x_i^J)^t$: c'est un vecteur de J dimensions.

⇒ est un point de l'espace R^J

- La variable $\underline{x}^j = (x_1^j, x_2^j, \dots, x_I^j)^t$: c'est un vecteur de I dimensions.

⇒ est un point de l'espace R^I

* si on s'intéresse à 1 variable le j est constant et les individus changent.

* si on s'intéresse à 1 individu le i est constant et les variables changent.

⇒ donc on peut faire 2 analyses différentes : on peut analyser les individus ou bien analyser les variables.

→ Analyse directe :

- c'est une analyse des individus.

- Nuage $N(I)$: des I individus dans l'espace R^J .

→ Analyse dualiste :

- c'est l'analyse des variables.

- Nuage $N(J)$: des J variables dans l'espace R^I .

exemples

→ analyser les variables, c'est dans un espace de dimension:

→ par exemple lorsqu'il s'agit des étudiants et des matières : J c'est le nombre de matières et I c'est le nombre de tous les étudiants par exemple $J = 14$ et $I = 300$

→ analyse directe des individus dans l'espace R^{14} , R^{14} , $\backslash R^{300}$

→ analyse directe des variables dans l'espace R^{300} .

exemples

des individus: sont les 92 régions françaises : Paris, Rhône-Alpes, Guyane, etc (lignes)

des variables: Démographiques, Économiques, Familiales, conditions de vie (colonnes)

→ sur chaque région on mesure un certain nombre de variables : les variables de nature démographiques, les variables de nature économique, les variables qui caractérisent la famille et les variables qui caractérisent les conditions de vie.

Démographiques: (variables démo)

- densité de population au Km^2 ,
- taux d'accroissement de la population, (chaque an du combien augmente la population)
- taux de natalité (= naissances vivantes pour 1000 habitants),
- taux de mortalité (= décès pour 1000 habitants)
- etc

→ tout ce qui caractérise la démographie dans cette région.

Variables économiques:

- Produit intérieur brut par habitant (qui est ce que la région produit par habitant)
- taux de chômage (par région),
- Part de population active travaillant dans le secteur agricole, (%)
- " " " " industriel, (%)
- " " " " des services - (%)
- etc.

Variables qui caractérisent la formation.

- proportion des sans diplômes dans la population de plus de 15 ans. (% des gens ayant aucun diplôme qui ont plus de 15 ans dans la région).
- proportions des diplômés du supérieur (\geq bac + 3),
- dépenses de la région par habitant pour la formation continue,
- etc.

Variables qui caractérisent les conditions de vie.

- proportion des ménages propriétaires de leur logement, (%)
- Nombre de médecins pour 1000 habitants,
- Nombre de lits d'hôpital pour 1000 habitants,
- Nombre de voitures pour 1000 habitants,
- etc.

→ pour le tableau de donnée : il va avoir cette forme :

→ les variables sont par blocs : si on connaît toutes les variables on va avoir plusieurs variables

Démog	Eco	Formation	conditions de vie
1			
2			
:			
:			
:			
92			

→ on peut avoir plus de variables que d'individus.

→ quand on fait une enquête, et on met des formulaires à remplir par des gens, on partage l'enquête par paquets de variables : on pose des questions sur l'âge, le nombre d'enfants,

est ce qu'il est marié ou pas - pour les variables économiques : le revenu de la personne, combien il a de comptes bancaires, pour la formation : niveau d'études, pour les variables de type conditions de vie : est ce qu'il est propriétaire de son logement, quelle est la surface de son logement ...

exemple :

→ on peut avoir comme individus des vaches et pour les variables on prend plusieurs mesures sur les vaches : l'âge de la vache, le poids, la taille, sa race (qualitative) mais on peut la transformer en variable quantitative en utilisant la Hot coding.

objectif :

Pour le mélange des individus $N(I)$

d'abord

- l'objectif c'est d'étudier le mélange des lignes (des individus) sur un espace de dimension j .
- à chaque individu à j dimensions, on cherche à la projeter par exemple en 2 dim. en perdant le moins d'information possible

- on met tous les individus dans un plan (étudiants par ex.)

- on sait que les étudiants rapprochés se ressemblent.

- ce groupe d'étudiants s'appelle à l'autre groupe

- si un étudiant est loin des autres on l'appelle une observation aberrante car il est différent

- des autres observations et il ne se compare pas comme les autres

→ on va déterminer aussi les observations aberrantes

⇒ ça c'est le mélange des individus

① Rechercher les groupes d'individus homogènes.

② Relever les différences entre groupes d'individus.

③ Mettre en évidence des éléments **individus atypiques**.

"
observations aberrantes

objectif

Pour le mélange des variables $N(j)$

on ne dit pas qu'une variable ressemble à une variable.

↳ on dit qu'une variable est corrélée avec une variable.

① Rechercher des groupes de variables corrélées.

② Construire des variables synthétiques non mesurées mais calculées.

Une variable synthétique, c'est par exemple une combinaison linéaire des variables qui

représente l'ensemble des variables par exemple, la moyenne, c'est une variable synthétique.

Il prend la moyenne d'un étudiant c'est une moyenne pondérée sur toutes les matières.
et ça se écrit le niveau d'un étudiant donc c'est une variable synthétique.

⇒ dans l'ACP aussi on va essayer de construire des variables synthétiques les plus parlant possibles.


→ ensuite on va s'intéresser à une analyse simultanée
objectif : Analyse simultanée de $N(I)$ et de $N(j)$.

c'est à dire on va essayer d'expliquer les lignes par les colonnes et les colonnes par les lignes.

o caractériser des groupes d'individus par des groupes de variables.

groupe d'étudiants

exemple :



→ on déduit que le 1^{er} groupe d'étudiants est bon en général en maths mais mauvais

en sport.

→ et le 2nd groupe d'étudiants est bon en sport mais mauvais en maths.

→ comment atteindre ces objectifs

⇒ Analyse du niveau des variables $N(j)$.

o pour chaque variable colonne x_j^i on calcule :

$$\text{sa moyenne : } \bar{x}_j^i = \frac{\sum_{i=1}^I x_i^j}{I} \quad (\text{la moyenne de toute la colonne})$$

= la moyenne de la variable

$$\text{sa variance : } S_j^2 = \frac{\sum_{i=1}^I (x_i^j - \bar{x}_j^i)^2}{I} \quad (\text{variance d'une colonne})$$

$$\text{son écart type : } s_j = \sqrt{S_j^2} \quad (\text{écart type d'une colonne})$$

→ on s'intéresse à un j quelconque et à une variable i .

→ ensuite, on effectue la transformation

$$x_i^j \rightarrow z_i^j = \frac{1}{\sqrt{I}} \cdot \frac{x_i^j - \bar{x}_j^i}{s_j}$$

c'est que chaque variable devra être centrée et réduite.

→ cette partie : $\frac{x_i^j - \bar{x}_j^i}{s_j}$ c'est centré et réduit, on ajoute $\frac{1}{\sqrt{I}}$ c'est une

constante qu'on verra son intérêt par la suite

\sqrt{I} = racine du nb d'individus.

→ donc finalement, presque chaque x_i^j a été transformé en z_i^j dans le tableau

$X = (x_i^j)$ il s'est transformé en un tableau $Z = (z_i^j)$

- l'individu x_i^j se transforme en un vecteur z_i^j ; $i = 1, 2 \dots I$. (ligne)

- La variable x_i^j se transforme en un vecteur z_i^j ; $j = 1, 2 \dots J$. (colonne)

→ Z a la même dimension que X (I lignes et J colonnes)

l'intérêt du Centrage et de la réduction,

on centre les données et on les reduit pour se débarrasser des unités

- si on multiplie les données $\times 100$ dans la moyenne sera $\times 100$ et l'écart-type sera multiplié $\times 10000$ (au carré) par conséquent lorsqu'on prend la racine on revient à $\times 100$ (l'écart-type)

$$x_i^j \rightarrow z_i^j = \frac{1}{\sqrt{I}} \cdot \frac{x_i^j - \bar{x}^j}{s_j} \quad \begin{array}{l} (\text{la moyenne} \times 100) \\ (\text{l'écart type} \times 100) \end{array}$$

→ donc ils se simplifient car si on mesure en m au lieu en cm on va obtenir la même valeur.

→ l'idée c'est de ramener les données à la même unité qui est sans unité en fait.

→ les grandes données deviennent petites. Parce que toutes les données multipliées par 100 vont se débarrasser de ce 100 \Rightarrow les données varieront à côté de 0.

exemple: comprend 3 données


1	100
2	200
3	300

$$\text{la moyenne} = 2$$

dans ce tableau la 2 pour ces données

$$\begin{aligned} 1 - 2 &= -1 \\ 2 - 2 &= 0 \\ 3 - 2 &= 1 \end{aligned}$$

↑ les données centrées



le 1 signifie qu'il a +1 que la moyenne et le -1 signifie -1 que la moyenne.


$$\text{moyenne} = 200$$

centrer les données:

$$100 - 200 = -100$$

$$200 - 200 = 0$$

$$300 - 200 = 100$$



on calcule la variance = la somme des carrés²

$$(-100 - 0)^2 + (0 - 0)^2 + (100 - 0)^2 = 20\ 000 \Rightarrow \text{la variance} = \frac{20\ 000}{2}$$

la variance pour les autres données (1, 2, 3)

$$(-1 - 0)^2 + (0 - 0)^2 + (1 - 0)^2 = 2$$

$$\text{la variance} = \frac{2}{2} = 1 \Rightarrow \text{l'écart type} = 1$$

si on divise les données centrées par l'écart type :

$$\begin{aligned}-1 &\Rightarrow \left(\frac{-1}{2}\right) \\ 0 &\Rightarrow 0 \\ 1 &\Rightarrow \left(\frac{1}{2}\right)\end{aligned}$$

les données centrées réduites

la variance de (100, 200, 300)

$$= \frac{20\ 000}{2} = 10\ 000 \Rightarrow \text{l'écart-type} = 100 \Rightarrow s = 100$$

réduire les données

$$-100 \Rightarrow \frac{-100}{100} = -1$$

⇒ c'est exactement comme les premiers (1, 2, 3)

$$0 \Rightarrow 0$$

$$100 \Rightarrow \frac{100}{100} = 1$$

donc si on multiplie les données par 100 ça va donner la même chose.

trouvez les données deviennent dans un intervalle bien défini ⇒ une échelle de grandeur.

⇒ c'est ça l'utilité du centrage et de la réduction.

exemple:

pour plusieurs clients on a des variables:

a)

Revenu

Epargne

1

2

3

4

5

les valeurs de l'Epargne sont plus petites que les valeurs du Revenu.

lorsqu'on centre et on réduit chaque colonne on va avoir la même échelle de valeurs

→ par exemple les valeurs du Revenu vont varier entre -2 et +2 ^{et} les valeurs de l'Epargne vont varier entre -2 et +2 ⇒ c'est pas les m^e va leurs mais ils vont avoir la même échelle.

pourquoi faire : c'est parce que après avoir fabriquer des variables synthétiques (c'est une moyenne pondérée de chaque ligne). donc lorsque vous avez le Revenu est nulle peu plus grand que l'Epargne ça fait des dispersions, mais lorsque vous avez des taux de même degré, la même échelle de valeur. nous faisons par exemple $C_1 \times \text{Revenu} + C_2 \times \text{Epargne}$ sur la même échelle de valeurs donc ils deviennent comparables. C'est pour cela qu'on réduit les écarts et on les centre.

Analyse des m^e des variables $N(j)$, E_{ff} et de la trame bimodale

→ la variable \underline{x}_i^j se transforme en vecteur \underline{z}_i^j .

$$\underline{z}_i^j = \begin{pmatrix} z_i^{j1} \\ z_i^{j2} \\ \vdots \\ z_i^{JI} \end{pmatrix} \quad \text{avec } z_i^{ji} = \frac{1}{\sqrt{I}} \cdot \frac{x_i^{ji} - \bar{x}^{ji}}{s_j}$$

→ si on calcule la moyenne des \underline{z}_i^j : $\frac{\text{la somme}}{I} \Rightarrow \text{la moyenne} = 0$

$$\begin{aligned} \text{la moyenne} &= \frac{\sum_{i=1}^I z_i^j}{I} = 0 \\ &= \frac{1}{\sqrt{I}} \cdot \frac{\sum_{i=1}^I x_i^{ji} - \sum_{i=1}^I \bar{x}^{ji}}{s_j} = \frac{1}{\sqrt{I}} \cdot \frac{I \cdot \bar{x}^{ji} - I \cdot \bar{x}^{ji}}{s_j} = 0 \\ s_j &= \text{cte} \end{aligned}$$

→ la moyenne = 0 ⇒ la variable est centrée c'est que la moyenne devient = 0

$$\rightarrow \text{et la variance} \Rightarrow \frac{\sum_{i=1}^I (z_i^j)^2}{I} = S_{z_j}^2 = X$$

$$\text{car } \frac{\sum_{i=1}^I (z_i^j)^2}{I} = \frac{1}{I} \sum_{i=1}^I \frac{(x_i^{ji} - \bar{x}^{ji})^2}{s_j^2} = \frac{s_j^2}{s_j^2} = X$$

$$\frac{\sum_{i=1}^I (x_i^{ji} - \bar{x}^{ji})^2}{I} = S_{\bar{x}^{ji}}^2$$

$$\text{et donc: } z_i^j = \frac{1}{\sqrt{I}} \cdot \frac{x_i^{ji} - \bar{x}^{ji}}{s_j}$$

$$\text{avec } S_j^2 = \frac{1}{I} \cdot \sum_{i=1}^I (x_i^{ji} - \bar{x}^{ji})^2$$

$$S_Z^2 = \frac{\text{la covariance de } Z^0}{I} = \frac{1}{I} \sum_{i=1}^I (x_i^0 - \bar{x}^0)^2$$

parce que la moyenne = 0

$$= \frac{1}{I^2} \cdot \frac{1}{S_0^2} \sum_{i=1}^I (x_i^0 - \bar{x}^0)^2$$

$$= \frac{1}{I}$$

la norme de Z^0 :

$$\|Z^0\|^2 = \sum_{i=1}^I (Z_i^0)^2 = 1$$

① des points variables se trouvent tous sur la sphère du centre O et de rayon 1
 (colonnes) dans l'espace dual \mathbb{R}^I : $\|Z^0\| = 1$

→ sphère de diam $I \Rightarrow$ hypersphère
 → si dim est en 3 dim \Rightarrow sphère

② la corrélation entre deux variables j et j' :

$$\rho(j, j') = \sum_{i=1}^I Z_i^j Z_i^{j'} = \langle Z^j, Z^{j'} \rangle = \cos(Z^j, Z^{j'})$$

* la division sur $A + \sqrt{I} \Rightarrow$ parfois la norme devient = 1

* et aussi 8

la corrélation entre 2 variables X (mat de maths) et Y (mat de physique) et on a N étudiants. Chaque étudiant on a sa mat de maths et de physique.

$$\begin{matrix} Z^1 & Z^2 \\ X & Y \end{matrix} \Rightarrow \text{la corrélation entre } X \text{ et } Y \text{ c'est la covariance:}$$

$$\frac{\text{cov}(X, Y)}{S_x S_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{S_x \cdot S_y}$$

$\rightarrow S_x$: l'écart type de X; S_y : écart type de Y

\rightarrow la corrélation est toujours entre -1 et +1. Si mesure la liaison linéaire entre X et Y.

→ si on calcule la corrélation entre Z^1 et Z^2 centrée:

$$\frac{\sum_i (Z_i^1 - 0)(Z_i^2 - 0)}{S_{Z^1} \cdot S_{Z^2}}$$

→ la moyenne de Z^1 et de $Z^2 = 0$ car ces 2 variables ont été centrées et réduites

→ le produit scalaire entre Z^1 et Z^2 .

$$\langle Z^1, Z^2 \rangle = \sum_{i=1}^I Z_i^1 \cdot Z_i^2$$

$$= \sum_{i=1}^I \frac{(x_i^1 - \bar{x}^1)}{S_1} \cdot \frac{1}{\sqrt{I}} \cdot \frac{1}{\sqrt{I}} \cdot \frac{(x_i^2 - \bar{x}^2)}{S_2}$$

$$= \sum_{i=1}^I \frac{1}{I} \cdot \frac{(x_i^1 - \bar{x}^1)(x_i^2 - \bar{x}^2)}{S_1 \cdot S_2}$$

pour que la covariance = $\frac{(x_i^1 - \bar{x}^1)(x_i^2 - \bar{x}^2)}{I}$

c'est exactement la corrélation entre x_1 et y

dans le produit scalaire devient la corrélation et la norme = 1.

$$\langle Z^1, Z^2 \rangle = \|Z^1\| \cdot \|Z^2\| \cdot \cos(Z^1, Z^2) = \cos(Z^1, Z^2) = \cos(x, y)$$

→ dans le produit scalaire c'est une corrélation

→ la corrélation entre 2 variables c'est le cosinus entre ces 2 vecteurs.

→ la norme de chaque vecteur = 1.

→ Toutes les variables se trouvent dans une sphère de norme 1

→ les angles entre les vecteurs (variables) c'est la corrélation.

• $\cos(Z^5, Z^6) = \text{corrélation entre } Z^5 \text{ et } Z^6$

• les variables Z^3 et Z^4 sont très corrélées parce que l'angle entre eux est très petit et donc le cosinus est grand.

corrélation négative très forte.

• les variables Z^6 et Z^3 ($\cos(Z^6, Z^3) = -1$) sont très corrélées négativement.
(par exemple la variable math et la variable sport)

* si on a 3 individus chaque variable a 3 dimensions (Vari p 16)

→ ces 3 variables sont corrélées négativement ça veut dire que lorsque l'une augmente l'autre va diminuer.

dim I ⇒ on est dans un espace de dim I.


→ si le I est très grand par exemple 300 étudiants : comme peut-on en voir dans un espace de dim 300

⇒ on doit prendre toutes les variables et les projeter sur un plan, donc il faut

chercher un bon plan pas n'importe quel plan: c'est le plan qui ne déforme pas les points Z^j (plan de projection)

→ plus le plan est étale plus on a perdu bcp d'informations.

exemples:
dans un plan on a les points suivants:



→ on ne peut plus travailler dans un plan de 2 dim, on va travailler sur 1 seule dimension. Càd on réduit les dimensions.

→ dans la meilleure direction sur laquelle on peut étre c'est la droite en reuze.

→ Chaque point, on le projete perpendiculairement sur cette droite, la distance entre les points devient maintenue

⇒ Par contre si on projette sur l'axe x on aura une déformation

⇒ Si on projette sur l'axe y c'est une déformation.

→ il faut chercher une droite tq en projetant dessus on perd la moins possible càd que les points restent les plus étalés possibles sur cette droite.

→ c'est la m^e idée lorsqu'on parle de plan, on cherche un bon plan de projection.

p 18 :

→ on a des points : les Z^j

→ Z^1 se projete en t^1 , Z^2 se projete en t^2

→ les plans étaient à l'intérieur d'une sphère donc après la projection ils deviennent à l'intérieur d'un cercle (cercle de corrélation)

→ si le point appartient à la surface de la sphère après la projection il va appartenir au périmètre du cercle.

→ les points projetés doivent être les plus étalés possibles.

→ si la projection des points se trouve en 0 ⇒ c'est très mauvais.

→ les points doivent être les plus dispersés possible et la distance 0 à 0 doit être la plus grande possible pour garder le max d'information.

Comment projeter les points pour que l'étalement soit le plus grand possible?

→ il faut chercher un plan tel que en projetant les points, les projections doivent être les plus étaillées possible.

→ les projections des z^j vont être dans un cercle.

p 19

→ les points doivent être loin de 0. Si ils sont sur le cercle c'est extraordinaire.

→ l'étalement global des projections ⇒ la somme des distances des t^j à 0, cette quantité doit être la plus grande possible.

⇒ l'idée est de chercher un plan tq la somme des normes des t^j soit la plus grande possible.

définir une mesure d'étalement:

$$\sum_{j=1}^J d^2(0, t^j) = \sum_{j=1}^J \|t^j\|^2$$

Inertie du
nuage J sur
le Plan E

doit être la plus grande possible.

→ c'est la dispersion des points variables autour de 0 dans la direction de E qui est appelé inertie et noté $I_m E$.

Propriété d'additivité de l'inertie (Pythagore).

si E et F sont deux sous espaces orthogonaux englobant le sous espace E+F on

$$I_m^{E+F} = I_m^E + I_m^F$$

↓
plan de
projection

• on projette z^j sur le plan, la projection de z^j sur le plan est y^j .

• $\|y^j\|^2 = \|t^j\|^2 + \|w^j\|^2$ pythagore

• ça veut dire que l'inertie des z^j on peut la calculer à des droites orthogonales

on cherche le meilleur vecteur de projection, on calcule l'inertie sur cette droite,

ensuite on cherche un autre vecteur orthogonal sur le premier et on calcule l'inertie

sur ce vecteur. Donc au lieu de chercher le meilleur plan de projection, on

cherche la meilleure 2^e droite de projection et on projette sur cette droite, ensuite

on cherche une droite perpendiculaire sur la 1^{re} droite, on projete, ensuite

on cherche une 3^e droite perpendiculaire sur les 2 premières droites et ainsi de suite. Parce que l'inertie s'additionne sur ces droites là. □
 → Finalement on va ramener la projection sur un plan ou sur un espace quelconque à la projection sur des vecteurs unitaires. A condition que les vecteurs unitaires que je choisisse soient orthogonaux les uns sur les autres.
 => l'inertie globale = la somme des inerties.

* on doit d'abord chercher le premier vecteur sur lequel on va projeter p22
 • l'inertie le long d'un axe dirigé par un vecteur unitaire \underline{v} à une expression matricielle simple:
 on cherche \underline{v} :

$$\|t^0\|^2 = (\underline{z}^0 \underline{v})^2 = (\underline{v}^T \underline{z}^0)(\underline{z}^0 \underline{v}) = \underline{v}^T (\underline{z}^0 \underline{z}^0) \underline{v}$$

la première vecteur sur lequel on va projeter

projection de \underline{z}^0 sur \underline{v}

$$t^0 = \langle \underline{z}^0, \underline{v} \rangle \quad \text{produit scalaire (matriciel)}$$

$$= (\underline{z}^0)^T \cdot \underline{v}$$

$\underline{v}^T \Rightarrow$ transposé

$$\underline{z}^0 = \langle \underline{z}^0, \underline{v} \rangle$$

vecteur unitaire sur lequel on va projeter \underline{z}^0

dans $\|t^0\|^2 = ((\underline{z}^0)^T \cdot \underline{v})^2 = ((\underline{z}^0)^T \cdot \underline{v})((\underline{z}^0)^T \cdot \underline{v}) = (\underline{z}^0)^T \underline{v} \underline{v}^T \underline{z}^0$

(on sait que $\langle a, b \rangle = \langle b, a \rangle = \sum a_i b_i$)

$$\|t^0\|^2 = (\underline{v}^T \cdot \underline{z}^0)((\underline{z}^0)^T \cdot \underline{v}) = \underline{v}^T (\underline{z}^0 (\underline{z}^0)^T) \underline{v}$$

dans $\sum_{j=1}^J \|t^j\|^2 = \sum_{j=1}^J \underline{v}^T (\underline{z}^j \underline{z}^{jT}) \underline{v} = \underline{v}^T \left(\sum_{j=1}^J \underline{z}^j \underline{z}^{jT} \right) \underline{v}$ Inertie sur \underline{v}

or $\sum_{j=1}^J \underline{z}^j \underline{z}^{jT} = (\underline{z}^1 \dots \underline{z}^j \dots \underline{z}^J) \begin{pmatrix} \underline{z}^1 \\ \vdots \\ \underline{z}^J \end{pmatrix} = \underline{z} \underline{z}^T$

$$\underline{z} = \begin{pmatrix} | & | & | \\ z^1 & z^2 & \dots & z^J \\ | & | & | \end{pmatrix}$$

dans $\text{Im}(\underline{v}) = \underline{v}^T (\underline{z} \underline{z}^T) \underline{v}$ a)

$$\underline{z}^T = \begin{pmatrix} | & | & | \\ \underline{(z^1)^T} & \underline{(z^2)^T} & \dots & \underline{(z^J)^T} \\ | & | & | \end{pmatrix}$$

l'inertie sur le vecteur \underline{v}

$$\text{Im}(\underline{v}) = \underline{v}^T \underline{z} \underline{z}^T \underline{v}$$

Inertie sur \underline{v} s

$$I = \underline{z} \underline{z}^T$$

: matrice d'inertie du nuage des variables elle est symétrique

définie positive.

dans $\text{Im}(\underline{v}) = \underline{v}^T \cdot I \cdot \underline{v}$

- R est symétrique car si on la transpose on va traverser la même chose.
- R est positive : c'est que tous ses valeurs propres sont positives ou nulles. (conséquence)

↳ comment la montrer ?

dimension de R est : $I \times I$ (I, I) matrice carrée

" " Z est : (I, J) avec I c'est le nb d'individus

" " Z' est : (J, I)

R : Symétrique $\Rightarrow R = Z \cdot Z^t$

$$R^t = (Z \cdot Z^t)^t = (Z^t)^t \cdot Z^t = Z \cdot Z^t = R$$

donc $R^t = R \Rightarrow R$ est symétrique

R : positive : une matrice A est définie positive si $x^t A x > 0$

$$\text{on prend } x \text{ de dim } (I, I) : x^t R x = x^t Z Z^t x = x^t Z^t Z x = (Z x)^t Z x = \underbrace{Z x}_{a}^t a > 0$$

donc $x^t R x > 0$ et donc R est positive.

c'est une matrice au carré

→ on cherche v qui rend Im^v la plus grande possible. c'est l'étalement le long de v est le plus grand possible

→ Z : connue, v : inconnue

chercher v : $\|v\| = 1$ (vecteur unitaire)

et $v^t R v$ maximal

$$v^* = \underset{\substack{v \\ \|v\|=1}}{\arg \max} v^t R v$$

le problème mathématique
on cherche le v qui maximise cette qté

$$\max \left(\frac{(v^t)^t R (v^t)}{\|v^t\|^2} \right) = \max \left(\frac{v^t R v}{\|v^t\|^2} \right) = \max_v \left(\frac{v^t R v}{v^t v} \right)$$

on cherche v tq $\frac{v^t R v}{v^t v}$ maximale \Downarrow $R = Z \cdot Z^t$ connue

on cherche la solution du problème : x : tq : $\frac{x^t A x}{x^t x}$ maximale

⇒ on va trouver que c'est le vecteur propre de A qui est associé à la plus grande valeur propre

v_1 = le vecteur propre de R associé à la plus grande valeur propre

→ on va montrer que :

* le vecteur (meilleur axe d'inertie) recherché est le vecteur propre v_1 associé à la plus grande valeur propre λ_1 de la matrice d'inertie $t = ZZ'$

→ si on a une matrice symétrique dans l'axe ses vecteurs propres sont orthogonaux.

→ une matrice symétrique est diagonalisable dans une base orthonormée

* donc le 2^e axe d'inertie est le vecteur propre v_2 associé à la 2^e plus grande valeur λ_2 de la matrice $t = ZZ'$

* etc

Le meilleur plan d'étalement du nuage est géométriquement par les 2 premiers vecteurs propres de l'assiette l'associés aux 2 plus grandes valeurs propres.

Résumé : pour trouver le meilleur plan de projection,

→ on prend la matrice X : on la centre et on la réduit : $X_i^{j*} = \frac{x_i^j - \bar{x}_i^j}{s_j}$

① calculer X^* : matrice centrée réduite

② calculer $t = \frac{1}{I} X^* X^{*t} = ZZ'$ $Z = \frac{X^*}{\sqrt{I}}$

③ rechercher les premiers vecteurs et valeurs propres de t ce sont les axes d'inertie.
 (→ associés aux plus grandes valeurs propres.
 → sur lesquels on va projeter)

$X \rightarrow Z \rightarrow t = ZZ^t \rightarrow$ diagonaliser t $\lambda_1 > \lambda_2 \dots \rightarrow \lambda_I$ (valeur propre)

→ le meilleur plan (v_1, v_2)

↓
vecteurs propres : $v_1, v_2 \dots v_I$

→ dim 3 → (v_1, v_2, v_3)

→ il y a des algos qui permettent de trouver v_1 et v_2 sans diagonaliser la matrice.

→ car diagonaliser → trouver I vecteurs propres (si I est grand dans on aura besoin de temps)

→ les éléments de la matrice Z : $Z_i^j = \frac{x_i^j - \bar{x}_i^j}{s_j}$

→ chaque vecteur propre a une valeur propre

→ on prend le vecteur propre associé à la valeur propre la plus grande. Ensuite

on prend le vecteur propre qui lui est orthogonal qui est associé à la 2^e plus grande valeur propre

⇒ pour trouver le plan de projection

- * les variables sont sur une sphère de centre 0, si on était en 3 dim, chaque variable aura 3 individus : individu 1, individu 2, individu 3.
- * on cherche le meilleur plan sur lequel les variables seront les plus étalées possibles, les variables : $z^1 \ z^2 \dots z^J$

→ le plan de projection est constitué de (v_1, v_2)

→ v_1 : vecteur propre associé à la plus grande valeur propre λ_1

→ v_2 : vecteur propre associé à la 2^e plus grande valeur propre λ_2

→ on doit projeter les variables z^j sur v_2

↳ on projette z^1 sur v_1 , z^2 sur v_2 , ..., z^J sur v_3 .

on note $G_\alpha(z^j) = (z^j)^t v_\alpha$: projection de z^j sur v_α
 $=$ coordonnée de z^j sur l'axe α

$\alpha = 1, \dots, I \mid j = 1, \dots, J$
 on a I vecteurs propres et I leurs propres.

$$G_\alpha = \begin{pmatrix} G_\alpha(1) \\ G_\alpha(2) \\ \vdots \\ G_\alpha(J) \end{pmatrix} = \begin{pmatrix} z^1 \\ \vdots \\ z^J \end{pmatrix} v_\alpha = z^t v_\alpha \Rightarrow G_\alpha = z^t v_\alpha$$

$$G_\alpha(z^j) = G_\alpha(z^j)$$

projection de toutes les variables sur l'axe α .

→ si on veut avoir les coordonnées de toutes les vari. projetées sur v_α on :

$$G_\alpha = z^t v_\alpha$$

→ on peut donc avoir les coordonnées de toutes les var. sur v_1 et sur v_2
 p. 33

on obtient qd chax comme ça (var).

→ on a toutes les variables des régions françaises projetées sur le meilleur plan de projection par ex: % des ménages propriétaires, le revenu par tête d'habitant, % de personnes seules, formation continue

→ projection sur le plan (v_1, v_2)

chaque variable a 2 coordonnées (G_1, G_2)

→ plus les variables sont petites et proches du cercle \Rightarrow donc lorsqu'on a projeté rien perdu (sur le cercle, les variables sont bien projetées)

- plus on s'éloigne du centre plus c'est mieux.
- les variables : revenu par tête d'habitant, PIB/habitant sont corrélées.
- plus les gens gagnent d'argent plus le revenu par habitant augmente
- les variables à droite caractérisent la richesse : → corrélées positivement
- les variables à gauche caractérisent la pauvreté : (% de ménages RMIS :)
l.
qui prennent des allocations familiales, taux de chômage, % de ménages
> 5 personnes → plus il y a de gens → plus on est pauvre → revenu par tête d'hab
diminue, % sans diplôme) ces var sont corrélées positivement entre eux.
- les variables à gauche sont corrélées négativement avec les var à droite.
- lorsque on projette on perd de l'information. Pour savoir combien on a perdu de
l'information, c'est avec les valeurs propres.
- * on suppose qu'on a 35 variables : $J = 35$
 - * et on a 22 nœuds : $I = 22$)
 - * la matrice Γ est de dim $I \times I = 22 \times 22$
 - dans on a 22 valeurs propres

λ_1 = première valeur propre

λ_2

:

→ sur l'axe (λ_1) on a la plus grande étendue

le pourcentage du 1^{er} axe : $\frac{\lambda_1}{\lambda_1 + \dots + \lambda_{22}} \times 100$ pourcentage d'information expliquée par le 1^{er} axe

→ chaque axe explique un pourcentage

ex : 1^{er} axe valeur propre = 16,7 % d'information = 52 %

le premier axe explique 52% d'information

deuxième (2nd) axe valeur propre $\lambda_2 = 4,68$ % d'information = 14,9%

dans le plan (v_1, v_2) explique 66,9% d'information = premier plan

de la matrice de donnée qu'on avait au début

→ on a perdu 34% de l'information

→ si on projette sur un espace de dim 3 % d'inertie = 77% cumulé

→ espace de dim 5 % d'inertie cumulé = 91, 90%

$\frac{5}{22}$ explique 91, 90% de l'information.

de var

→ c'est l'ACP du nuage des variables.

→ pour la suite il faudra faire l'ACP des nuages des individus.

* on s'intéresse au vecteur des lignes.

* chaque individu Z_i du nuage $N(I)$ est une ligne du tableau de données.
C'est un vecteur de \mathbb{R}^J .

* donc au lieu de refaire toute l'analyse, il suffit de transposer la matrice, transposer le tableau de données et refaire l'analyse dans Z' au lieu de Z .

→ les variables vont jouer le rôle des individus.

→ les individus vont jouer le rôle des variables.

$V = Z'Z$, matrice d'inertie du nuage.

↳ qu'il faut la diagonaliser pour trouver les valeurs propres.

Télécharger Tamagno : logiciel de data mining (voir la documentation)

↳ ACP, clustering, K-means,

TD 1

Exercice 2 : arbres de décisions :

Rappel : Pour un noeud t de l'arbre contenant les K probabilités (fréquences)

d'un label de K classes t : $P_1 \ P_2 \ \dots \ P_K$

Entropie (t) = $-\sum_{e=1}^K P_e * \log(P_e)$ le logarithme est calculé en base 2

Erreur (t) = $1 - \max(P_1, P_2, \dots, P_K)$

Gini (t) = $1 - \sum_{e=1}^K P_e^2$

A remarquer qu'après le partage d'un noeud t en deux noeuds binaires gauche : t_g et droite : t_d , la mesure d'un indice après ce partage par exemple pour

$Gini(\text{après partage}) = f_g * (Gini(t_g)) + f_d * (Gini(t_d))$ où f_g et f_d représentent

les poids (en termes de fréquences d'éléments de la partie gauche et la partie droite) respectivement.

ex: on considère le fichier d'apprentissage du tableau suivant pour une classification binaire:

Instance	a_1	a_2	a_3	La classe
1	T	T	1	+
2	T	T	6	+
3	T	F	5	-
4	F	F	4	+
5	F	T	7	-
6	F	T	3	+
7	F	F	8	+
8	T	F	7	-
9	F	T	5	-

T : true

F : false

→ le gain est calculé à partir de l'entropie ou à partir de Gini.

→ 3 mesures pour construire un arbre de décision: gini, entropie, erreur.

stata virginica

versicolor

$$Gini(t) = 1 - \left(\frac{1}{3}\right)^2 \times 3 = 1 - \frac{1}{3} = \frac{2}{3}$$

$$\text{Entropie}(t) = -\frac{1}{3} \log \frac{1}{3} - \frac{1}{3} \log \frac{1}{3} - \frac{1}{3} \log \frac{1}{3} = -\log \frac{1}{3} = \log 3$$

$$\text{Erreur}(t) = 1 - \frac{1}{3} = \frac{2}{3}$$

↳ c'est que chaque mélèze a l'affection à la classe majoritaire, donc c'est l'une parmi les 3, donc on se trompe sur les 2 autres.

→ on se trompe 2/3 du fois.

① Ecrivez les formules de l'entropie, de l'erreur et de l'indice de gini

en fonction de K dans le cas de l'équiprobabilité.

m probabilités

• équiprobabilité $\Rightarrow P_i = \frac{1}{K}$ $1 \leq i \leq K$

donc :

$$Gini(t) = 1 - \frac{1}{K^2} \times K = 1 - \frac{1}{K}$$

$$\text{Entropie}(t) = -\sum_{j=1}^K \frac{1}{K} \log \left(\frac{1}{K}\right) = \log_2(K)$$

$$\text{Erreur}(t) = 1 - \frac{1}{K}$$

$$K = 2 \rightarrow \text{malade} - \text{non malade} \quad \text{Entrapie}(k) = \log_2(2) = 1$$

\rightarrow c'est que pour envoyer un message de langage 2 c'est 1 bit.

\rightarrow Entrapie : donne le nb moyen de bit qu'il faut pour envoyer des messages qui ont pour chacun une probabilité p_j


Equation probabilité : $G_{\text{imi}} = 1 - \frac{1}{K}$

$$\text{Entrapie} = \log_2(k)$$

$$\text{Erreur} = 1 - \frac{1}{K}$$

② Ecrire les formules de l'entrapie, de l'erreur et de l'indice de Gini pour le cas où le label est binaire (deux classes) ($p, 1-p$). Tracer les 3 fonctions mesurées sur un seul graphique en fonction de p (commun à toutes).

$$K = 2$$




$$\rightarrow G_{\text{imi}} = 1 - p^2 - (1-p)^2 = 1 - p^2 - 1 - p^2 + 2p = 2p - 2p^2$$

$$G_{\text{imi}} = 2p(1-p)$$

$$\rightarrow \text{Entrapie} = -p \log p - (1-p) \log(1-p)$$

$$\rightarrow \text{Erreur} = 1 - \max(p, 1-p)$$

cas $K=2$:




\rightarrow lorsque $p=0$ ou $p=1$ l'impureté est nulle, les 3 mesures s'annulent.

\rightarrow les 3 mesures prennent leur maximum dans $1/2$.


pour mesurer l'impureté dans un modèle.

③ quelle est l'entrapie de cette collection d'instances 50% à la classe positive.



$$\text{Entropie}(t) = - \left(\frac{4}{9} \log \frac{4}{9} + \frac{5}{9} \log \frac{5}{9} \right) = 0,9911$$

① quels sont les gains d'information « information gain » correspondants à a_1 et a_2 respectivement.
on split



$$\text{Entropie}(tg) = - \frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4}$$


$$\text{Entropie}(td) = - \frac{1}{5} \log \frac{1}{5} - \frac{4}{5} \log \frac{4}{5}$$

$$\text{Entropie(mieux)} = \frac{4}{9} \text{Entropie}(tg) + \frac{5}{9} \text{Entropie}(td) = 0,7616$$

$$\Rightarrow \text{gain} = 0,9911 - 0,7616 = 0,2295$$

entropie diminue lorsqu'on split sur a_1 .

a_2 on split sur a_2



$$\text{Entropie} = \frac{5}{9} \text{Entropie}(tg) + \frac{4}{9} \text{Entropie}(td) = 0,9838$$

$$\text{gain} = 0,9911 - 0,9838 = 0,073 \text{ très petit}$$

→ donc sur a_1 on gagne plus

$$\text{gain}(a_1) = 0,2295$$

$$\text{gain}(a_2) = 0,073$$

→ l'attribut qui permet de gagner plus en pureté c'est a_1 .


- ⑤ Pour a_3 qui est un attribut continu, calculer le gain d'information pour chaque partage possible. Un partage sur une valeur de a_3 correspond à la valeur moyenne de 2 valeurs consécutives de a_3 true.
- / moyenne entrainie lorsqu'on partage par 2

a_3

a_3	label	split	Entrapie	Gain
1	+	2	0,8484	0,1427
3	-	3,5		
4	+	4,5	0,9834	0,0072
5	-	5,5		
6	+	6,5		
7	+	7,5		
7	-			
8	-	-		

le plus grand gain c'est lorsqu'on partage par 2 donc c'est celle là qu'en va utiliser

partage par 2




on calcule l'entropie droite et gauche ensuite l'entropie du partage

$$\text{gain}(a_1) = 0,2295$$


$$\text{gain}(a_2) = 0,073$$

$$\text{gain}(a_3) = 0,1427 \text{ gain du meilleur partage de } a_3$$

⇒ le meilleur attribut = celui qui a donné le meilleur gain = a_1



- ⑥ quel est le meilleur partage parmi a_1 et a_2 selon le taux d'erreur.




$$\text{Erreur}(t) = \frac{4}{9}$$

$$\text{Erreur(miveau)} = \frac{4}{9} \times \frac{1}{4} + \frac{5}{9} \times \frac{1}{5} = \frac{2}{9}$$

$$\underline{\underline{a_2}} \quad \text{Erreur}(a_2) = \frac{4}{9}$$

→ donc c'est l'ajourus a_2 qui est le meilleur.




$$\text{Erreur}(tg) = \frac{3}{5}$$

$$\text{Erreur}(td) = \frac{1}{2}$$

$$\text{Erreur}(a_2) = \frac{4}{9} \times \frac{3}{5} + \frac{5}{9} \times \frac{1}{2} = ? \text{ vérifier}$$

① Quel est le meilleur partage parmi a_1 et a_2 selon l'indice de gini.




$$Gini(t) = 1 - \left(\frac{4}{9}\right)^2 - \left(\frac{5}{9}\right)^2$$

$$Gini(tg) = 1 - \left(\frac{3}{4}\right)^2 - \left(\frac{1}{4}\right)^2$$

$$Gini(td) = 1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2$$

$$Gini(a_1) = \frac{4}{9} Gini(tg) + \frac{5}{9} Gini(td)$$

* Remarque :



Indice
Indice(t)
← gini
erreur
entropie

$$\text{Indice(miveau 1)} = f_{tg} \text{ Indice}(tg) + f_{td} \text{ Indice}(td)$$

Branche gauche

NB

$$\underline{\underline{\text{gain}}} = \text{Indice}(t) - \text{Indice(miveau 1)} > 0 \quad \triangleleft$$

$$f(t_1) + f(t_2) \geq f(t_1 + t_2) \quad \text{convexité}$$

$$f[t_1 + (1-\lambda)t_2] \leq \lambda f(t_1) + (1-\lambda)f(t_2) \quad \text{convexité}$$

seconde (3): 24 - 05 2021

→ on écarte les données pour en faire les plus importants.

→ on garde le signal et on laisse tomber tout ce qui est bruit.

→ le point départ c'est un tableau (p_2): on a des lignes: I lignes, si on veut les représenter, ils sont dans un espace de dim J, par exemple chaque ligne représente les notes d'un étudiant, c'est que chaque étudiant est dans l'espace des notes et chaque matière est dans l'espace des individus (I individus).

→ **l'Analyse dual**, analyse des variables dans l'espace des individus.

- chaque variable est dans un espace \mathbb{R}^I

→ **P' Analyse directe**: analyse des individus dans l'espace des variables.

* la dernière fois on a : Analyse directe $\xrightarrow{\text{fait}}$ individus $\xrightarrow{\text{variables}}$

o on est parti d'un tableau X de dim $I \times J$, c'est un tableau (x_{ij}^*)

o on crée un tableau X^* : $X \xrightarrow{\quad} X^* \neq \text{dim } I \times J$

$$x_i^{*j} = \frac{x_i^j - \bar{x}_i^j}{s_j} \quad \text{centrage et réduction}$$

pour avoir des variables mémorisées: $X^* \xrightarrow{\quad} Z = \frac{1}{\sqrt{m}} X^* \text{ avec } z_i^j = \frac{x_i^{*j}}{\sqrt{m}}$

Z est un tableau de dim $I \times J$.

o à partir de Z on fabrique la matrice d'inertie $\Gamma = Z Z^t$ de dim $I \times I$

o avec la matrice Γ on va trouver les vecteurs propres, ce sont les vecteurs sur lesquels on va projeter les variables.


o on cherche les valeurs propres $\lambda_1 > \lambda_2 > \lambda_3 \dots > \lambda_n$ et les vecteurs propres associés v_1, v_2, \dots, v_n avec $n = \text{rang}(Z)$, on ne peut pas aller plus que le rang car après le rang les valeurs propres sont nulles.

$$n = \text{rang}(Z) \leq \min(I, J)$$

o une fois on a les vecteurs propres, on commence à projeter les variables.

o par exemple on projette la variable 1 sur v_1 : $G_{v_1}(1) = (Z^t)^k \cdot v_1$

$G_{v_2}(z) = (z^1)^t \cdot v_2$. Donc on a 2 coordonnées de la variable z^1 , c'est-à-dire sur v_1 et coordonnées sur v_2 . Donc on peut représenter la variable z^1 sur le plan (v_1, v_2) .



→ on fait la même chose pour toutes les variables.

→ les angles entre les variables représentent les corrélations.

→ et donc on peut représenter toutes les variables sur le plan (v_1, v_2) et c'est le meilleur plan de projection, c'est à dire qu'en projetant les variables sur ce plan on perd le moins d'informations possible, on compressé les informations qu'on avait dans un espace de dim I dans un espace de dim 2 et (v_1, v_2) c'est le meilleur espace pour cela.

→ ensuite on a toutes les var représentées sur un espace de dim 2 au lieu qu'ils soient représentées dans un espace de dim I qui peut être assez grand (6M clients, 900 étudiants ...)

→ les projections des variables se trouvent dans un cercle unitaire.


$$\underline{G_{v_x}(j)} : \text{projection de } z^j \text{ sur } v_x \\ = (z^j)^t \cdot v_x = \frac{(z^j)^t \cdot v_x}{\|z^j\| \cdot \|v_x\|}$$

car $\|z^j\| = \|v_x\| = 1$
vecteurs unitaires

$$G_{v_x}(j) = \cos$$

donc $-1 \leq G_{v_x}(j) \leq 1$

donc toutes projections seront à l'intérieur d'un cercle unitaire.
des variables



22 régions : lignes

variables économiques : calomme

→ on a la projection de toutes les variables sur le plan (U_1, U_2)

→ on remarque que le revenu par habitant est très corrélé avec PIB/habitant.

car l'angle entre eux est très petit = corrélation.

→ la variable parc auto / habitant est corrélée avec la mortalité, plus il ya des automobiles plus il ya des accidents.

→ plus il y a des automobiles plus le % personne active dans l'industrie est grand, donc c'est corrélé.

→ Tant ce qui se trouve proche du cercle, lorsqu'on la projette, il était pratiquement déjà proche du cercle, on a rien perdu lorsqu'on les a projeter.

→ on était dans un espace de dim 22 et maintenant on est dans un espace de dim 2.

→ sur espace de dim 2 : l'inertie cumulé = 66,7% donc on a perdu 33,96% de l'information, c'est les 2 premières valeurs propres représentent 66,7%

de l'information. On peut aller jusqu'à 22 (dim 22)

→ lorsque les variables sont proche du cercle après la projections ils sont très proches du cercle.

Analyse du mélange des individus N(I) :

- chaque individu est un vecteur $Z_i \in \mathbb{R}^J$, donc il peut être représenté dans un espace de dim J avec J le nb de variables.
- au lieu de refaire tout dès le début, il suffit de transposer la matrice Z. Les individus deviennent les variables et les variables deviennent les individus

• la matrice d'inertie : $V = Z'Z$ de dim $J \times J$

• il faut diagonaliser V pour trouver ses vecteurs propres et c'est sur ces vecteurs propres qu'on va projeter les individus.

Réultat :

- * $\Gamma = ZZ^t$ et $V = Z^t Z$. possèdent les m^e valeurs propres matricielles.
- matrice d'inertie des variables des individus
- les valeurs propres nulles de Γ sont aussi dans V .
- * les vecteurs propres de V : u_1, u_2, \dots et les vecteurs propres de Γ : v_1, v_2, \dots sont reliés par la formule :
- $$u_\alpha = \frac{Z \cdot v_\alpha}{\sqrt{\lambda_\alpha}} \quad \text{et} \quad v_\alpha = \frac{Z \cdot u_\alpha}{\sqrt{\lambda_\alpha}}$$

on peut diagonaliser soit Γ soit V et déduire les vecteurs propres de l'autre, et les valeurs propres sont les m^e.

$$\Rightarrow \Gamma = ZZ^t \text{ de dim } I \times I \quad Z \text{ de dim } I \times J$$

$$V = Z^t Z \text{ de dim } J \times J$$

\Rightarrow si on a plus de variables que d'individus on diagonalise Γ .

\Rightarrow si on a plus d'individus que de variables il vaut mieux diagonaliser V .

En général : le nb d'individus dépasse le nb de variables.

* 300 étudiants et 15 matières

* des milliers de malades sur lesquels on mesure des tests médicaux.

\Rightarrow On généralise on diagonalise V .

preuve :

$$\Gamma = ZZ^t \quad \text{et} \quad V = Z^t Z$$

on suppose qu'on a diagonalisé Γ donc on connaît les v_α .

dans $\Gamma \cdot v_\alpha = \lambda_\alpha v_\alpha$ avec λ_α valeur propre associée à v_α .

$$\text{dans } ZZ^t = \Gamma \Rightarrow ZZ^t v_\alpha = \lambda_\alpha v_\alpha$$

$$\Rightarrow Z^t (ZZ^t v_\alpha) = Z^t (\lambda_\alpha v_\alpha)$$

$$\Rightarrow Z^t ZZ^t v_\alpha = Z^t \lambda_\alpha v_\alpha$$

$$\Rightarrow V Z^t v_\alpha = \lambda_\alpha Z^t v_\alpha$$

dans la vecteur $Z^t v_\alpha$ est un vecteur propre de V

dans si v_α est un vecteur propre de T alors $Z^t v_\alpha$ est un vecteur propre de V
+ ils ont la m^e valeur propre.

→ V a des vecteurs propres car elle aussi est symétrique définie positive. Donc elle est diagonalisable dans un espace euclidien.

→ Donc il suffit de montrer que v_α est vecteur $Z^t v_\alpha$.

→ on suppose que $u_\alpha = \frac{Z^t v_\alpha}{\|Z^t v_\alpha\|}$ pour que le vecteur soit unitaire

$$\begin{aligned} \|Z^t v_\alpha\|^2 &= v_\alpha^t Z^t Z Z^t v_\alpha = v_\alpha^t I \cdot v_\alpha = v_\alpha^t I v_\alpha = v_\alpha^t \lambda_\alpha v_\alpha = \lambda_\alpha \|v_\alpha\|^2 \\ \Rightarrow \|Z^t v_\alpha\|^2 &= \lambda_\alpha \end{aligned}$$

Donc $u_\alpha = \frac{Z^t v_\alpha}{\sqrt{\lambda_\alpha}}$ d'où le résultat.

on peut faire la m^e démarche pour trouver que $v_\alpha = \frac{Z u_\alpha}{\sqrt{\lambda_\alpha}}$

→ on me demande que le vecteur de T ou de V ça dépend de la dimension.

→ les valeurs propres sont les mⁱ, donc on n'a pas besoin de diagonaliser l'automatique

→ et les vecteurs propres se déclinent les uns des autres.

* mais qu'en a les vecteurs u_α on va projeter les individus sur ce vecteur.

Parce que le meilleur plan de projection c'est:

→ le vecteur (meilleur axe d'inertie) recherché est le vecteur propre u_1 associé à la plus grande valeur propre λ_1 de la matrice d'inertie $V = Z^t Z$

→ le 2^{me} axe d'inertie est le vecteur propre u_2 associé à la 2^{me} grande valeur λ_2 de la matrice d'inertie $V = Z^t Z$

→ etc

⇒ le meilleur plan d'étalement du nuage $N(I)$ est générée par les deux premiers vecteurs propres de V associés aux deux plus grandes valeurs propres.

$$V = Z^t Z, J \times J : \lambda_1 > \lambda_2 > \dots > \lambda_n$$


u_1, u_2, \dots, u_n

meilleur plan de projection

→ si on veut par exemple projeter un étudiant sur u_1 :

$$F_{u_1} \text{ (étudiant 1)} = (\text{étudiant 1})^t \cdot u_1$$

$$F_{u_2} \text{ (étudiant 1)} = (\text{étudiant 1})^t \cdot u_2$$



→ on peut maintenant représenter tous les étudiants dans un plan.

→ puisque la norme de l'étudiant 1 # 1 donc sa valeur F_{u₁} (étudiant) n'est pas forcément à l'intérieur d'un cercle.

→ on peut donc représenter à la fois les étudiants dans un espace (u₁, u₂) et on peut aussi représenter les variables dans un espace (v₁, v₂).

Résumé :

après transformation : on a la matrice Z = .

individu 1	var 1		var 2	
	z ¹	z ²	z ¹	z ²
individu I				

on projette la var 1 sur v₁ et sur v₂

$$\hookrightarrow G_{v_1}(1) \text{ et } G_{v_2}(1)$$

→ on a projeté toutes les variables sur v₁.

$$G_{\alpha}(j) = (Z^t)^t \cdot v_\alpha$$

(v₁, v₂) : meilleur plan

→ donc on a les coordonnées de toutes les variables sur l'axe 1 et sur l'axe 2

donc on peut les représenter sur un plan

→ on fait la même chose pour les individus

individu	v ₁	v ₂
individu 1		
individu 2		
individu I		

F _{u₁} (1), F _{u₂} (1)	F _{u₁} (1), F _{u₂} (1)
F _{u₁} (2), F _{u₂} (2)	F _{u₁} (2), F _{u₂} (2)
F _{u₁} (I), F _{u₂} (I)	F _{u₁} (I), F _{u₂} (I)

F _{u₁} (1), F _{u₂} (1)	F _{u₁} (1), F _{u₂} (1)
F _{u₁} (2), F _{u₂} (2)	F _{u₁} (2), F _{u₂} (2)
F _{u₁} (I), F _{u₂} (I)	F _{u₁} (I), F _{u₂} (I)

- on a projeté tous les individus sur (u_1, u_2)
- la projection de tous les individus sur u_1 et la projection de tous les individus sur u_2
- on compressera la matrice : au lieu d'avoir J coordonnées on a que 2 coordonnées pour chaque individu m à que 2 coordonnées au lieu de J .
- la m^e chose pour les variables : on compressera la matrice des J côtés et au lieu d'avoir pour chaque variable I coordonnées on a que 2 coordonnées
- ⇒ Donc on peut représenter les individus dans un espace de dim 2 et représenter les variables sur un espace de dim 2
- on peut également v_3 et u_3 , mais à partir de 3 on ne comprend plus rien, c'est un peu difficile d'imaginer ça
- Par contre, le meilleur plan ça sera facile de projeter.
- ACP → prendre ce qui est principale et laisser tomber ce qui est secondaire

Commentaires : sur le graphique

- les lignes représentent les individus on a I individus.
- les colonnes représentent les variables on a J variables.
ex : les étudiants (individus) et les matières (variables)
- on peut faire une analyse dual et une analyse directe.
- notre but est d'avoir le meilleur plan de projection pour les variables et pour les individus
- pour le plan de projection des variables, on obtient les 2 vecteurs propres v_1 et v_2 ce sont les vecteurs propres de la matrice $Z Z^T = r$
- les coordonnées des variables sont : $\begin{pmatrix} g_{v_1}(1) \\ g_{v_2}(1) \end{pmatrix}$ coordonnées de la variable 1 sur les vecteurs propres v_1 et v_2 .
- chaque variable a une dimension au début, maintenant elle a que 2 dim.
- on projette les individus sur les vecteurs u_1 et u_2 . Au début un individu avait J variables et maintenant il a que 2 coordonnées. $\begin{pmatrix} F_{v_1}(1) \\ F_{v_2}(1) \end{pmatrix}$

p38

en projette sur le plan (u_α, u_β).
les individus ce sont les n'gams.

p39

la coordonnée du point individus i sur l'axe α (\vec{u}_α) est donnée par le produit

$$\text{scalaire : } F_\alpha(i) = \vec{z}_i \cdot \underline{u}_\alpha$$

En empilant ces équations on obtient le vecteur formé par toutes les coordonnées des variables sur l'axe α :

$$F_\alpha = \begin{pmatrix} F_\alpha(1) \\ F_\alpha(2) \\ \vdots \\ F_\alpha(i) \\ \vdots \\ F_\alpha(I) \end{pmatrix} = \begin{pmatrix} \vec{z}_1 \cdot \underline{u}_\alpha \\ \vec{z}_2 \cdot \underline{u}_\alpha \\ \vdots \\ \vec{z}_i \cdot \underline{u}_\alpha \\ \vdots \\ \vec{z}_I \cdot \underline{u}_\alpha \end{pmatrix} = \vec{z} \cdot \underline{u}_\alpha$$

$$F_\alpha = \vec{z} \cdot \underline{u}_\alpha$$

$$1 \leq \alpha \leq n = \text{rang}$$

projection de toutes les individus sur l'axe α .

p40

Remarque

on peut écrire aussi : $F_\alpha = \vec{z} \cdot \underline{u}_\alpha = (\vec{z}^1, \vec{z}^2, \dots, \vec{z}^j, \dots, \vec{z}^J)$

$$\begin{pmatrix} \underline{u}_\alpha^1 \\ \underline{u}_\alpha^2 \\ \vdots \\ \underline{u}_\alpha^j \\ \vdots \\ \underline{u}_\alpha^J \end{pmatrix}$$

$$F_\alpha = \sum_j \underline{u}_\alpha^j \vec{z}^j$$

$$\text{car } \vec{z} = (\vec{z}^1, \vec{z}^2, \dots, \vec{z}^J) = \begin{pmatrix} \vec{z}_1 \\ \vec{z}_2 \\ \vdots \\ \vec{z}_I \end{pmatrix}$$

$$F_\alpha = \vec{z}^1 \underline{u}_\alpha^1 + \vec{z}^2 \underline{u}_\alpha^2 + \dots + \vec{z}^J \underline{u}_\alpha^J$$

\Rightarrow un composante principale c'est une combinaison linéaire des variables.

F_α : est une combinaison linéaire des variables, une sorte de variable de synthèse


appelée : Factor principal α

• Composante principale α

→ on maximise on a ~~pas~~ au maximum $\text{rang}(Z)$ de F_k (car on peut avoir que n vecteurs propres).

exemple

* supposons qu'on a 2 variables, maths et physique. Le tableau de données contient les étudiants (les lignes) et les matières (les colonnes).
→ chaque individu a deux coordonnées (maths et PC).



→ la 1ère composante principale


- centrer : ça veut dire changer le centre de gravité des individus
- chercher les vecteurs propres : ça veut dire chercher comment projeter les individus dans l'espace des variables.

→ on cherche donc l'axe sur lequel les individus sont les plus étalés possible (l'axe en vert) donc on a 1 seule composante principale on n'a pas besoin de la 2ème dans cet exemple : si on diagonalise la matrice on va trouver 1 seul vecteur propre. L'autre sera nulle, elle ne représente rien du tout, c'est qu'elle ne contient aucune information.

→ Lorsqu'on va faire la projection, tout individu va se trouver sur l'axe en vert

→ donc il y a une seule composante principale, on peut ajouter une autre mais elle ne contient rien. Tous se projettent sur l'axe en vert.

exemple



→ si on fait l'ACP on obtiendra l'axe en vert.

→ est-ce qu'il vaut mieux projeter les individus sur les maths ou sur la physique ?

⇒ Physique, car en projetant sur l'axe de la physique les individus seront les plus étalés possibles.

- on cherche l'axe sur lequel on a plus d'étalement
- pour l'ACP → on trouve que le meilleur axe c'est celui qui est en vert car on
ne perd rien en projetant sur cet axe.
- Par contre en projetant sur les maths on perd qq chose
- Lorsqu'on projette sur l'axe de physique c'est vrai qu'on a plus d'étalement mais
perd un peu d'information.
- l'ACP ⇒ cherche les meilleurs axes d'inertie, sur lesquels on a plus d'étalement.

ACP : démonstration avec python (voir le fichier « pymb »)

ACP-SUR-IRIS « pymb »

- ACP des iris, c'est des fleurs, chaque fleur a 4 caractéristiques, on avait 150 fleurs et 3 catégories de fleurs

→ la 1^{re} chose qu'on fait c'est d'importer les bibliothèques dans lesquelles on a besoin.

→ **uci** : c'est un site contenant plusieurs fichiers de données. △

→ url = " " : l'url du fichier iris dans le site uci. [affichage]

→ on lit le fichier de données avec pandas + on lui donne les noms des variables : long petal ---- + la classe.

→ df.head() : pour voir les 5 premières observations.

→ ensuite on définit les variables features = ['sepal length', ... -]

↳ on constitue la matrice X, car on fait l'ACP donc on oublie la target (la classe), on l'utilise juste pour la couleur.

→ on le met dans X : **X = df.loc[:, features].values**

→ on met la target dans Y : **y = df.loc[:, ['target']].values**

$X = x$

↳ on l'utilise juste pour le coloriage.

→ ensuite on centre et on réduit **x = StandardScaler().fit_transform(X)**

→ on a besoin de 2 composantes principales : **pca = PCA(n_composants=2)**

F₁ et F₂ car on fait de l'ACP sur les individus.

→ on calcule v₁ et v₂ : **principalComponents = pca.fit_transform(X)**

on les projette.

→ on met F₁ dans la composante principale 1 et F₂ dans la composante

principale 2.

principalDf = pd.DataFrame (data = principalComponents, columns = [
'principal component 1', 'principal component 2'])
→ on affiche les 5 premières campasantes principales. principalDf.head(5)
individus projetés sur les

→ si on fait principalDf.shape $\Rightarrow (150, 2)$

lmb de lignes et colonnes
 \Rightarrow on obtient 2 colonnes et 150 lignes.

→ les 2 colonnes sont les 2 campasantes principales.

→ les coordonnées des individus sur les 2 campasantes principales.

→ c'est qu'on projette toutes les fleurs qui avaient 4 variables sur la 1^{ère} comp
principale et sur la 2^{ème} campasante principale. Maintenant elles ont que 2 coordonnées.

df[['target']].head() catégories pour les 5 premières fleurs.


→ maintenant on va concaténer les campasantes principales avec leur target.

finalDf = pd.concat([principalDf, df[['target']]], axis = 1)

finalDf.head()

\Rightarrow afficher les 5 fleurs : leurs 2 campasantes principales et leur target.

→ Maintenant on va faire la projection sur F₁ et F₂ (voir la suite)



* chaque axe a une valeur propre

$$\begin{matrix} \lambda_1 & \lambda_2 \\ \lambda_3 & \lambda_4 \\ \vdots & \vdots \\ \lambda_g & \lambda_g \end{matrix}$$

l'axe α explique le max d'information $\lambda_1 > \lambda_2 \dots > \lambda_J$

→ le pourcentage : $\frac{\lambda_\alpha}{\sum \lambda_j} \times 100\%$

$$\frac{\lambda_1}{\sum \lambda_j} \times 100\%$$

→ chaque axe explique un pourcentage

pca - explained variance ratio -

⇒ array ([0.72770452, 0.23030523])

Pourcentage d'information expliquée par la 1^{ère} composante principale

Pourcentage d'information expliquée par la 2^{ème} composante principale.

⇒ le premier plan (u_1, u_2) explique 0,95% de l'information.

→ donc on a pas perdu bcp d'info en projetant sur un espace de 2 dim de 4 dim à 2 dim sans perdre bcp d'info

ACP : avec Kmime, :

Voir TPh

ACP : avec Tamagna

Voir TPh + voir documentation de Tamagna.

Exercice p 4.1 :

→ Prouver que la variable F_α est la moyenne nulle $\left(\frac{\sum_{i=1}^I F_\alpha(i)}{I} = 0 \right)$
 F_α : coordonnées de tous les individus sur l'axe α .


F_α est de dimension I

$F_\alpha(1), F_\alpha(2) \dots F_\alpha(I)$

→ on veut montrer que la moyenne des F_α est nulle pour nimporte quel facteur (vecteur)

et l'invariance = $\frac{\lambda_\alpha}{I}$

→ F_α : projection des individus sur l'axe α .



il faut avoir des coordonnées négatives et d'autres positives puisque la moyenne soit nulle.

2e)
rel.
rel.

4-)

int.)

tres

α fixé

$$\sum_{x=1}^I F_\alpha(x) = 0$$

$$\bar{F}_\alpha = \frac{\sum_{x=1}^I F_\alpha(x)}{I} = 0 \quad \text{à mantrer}$$

cad que si on projette les individus sur un axe qui aura des coordonnées


positifs et d'autres négatifs \Rightarrow il est toujours centré sur 0.

$$\rightarrow \bar{F}_\alpha = \frac{\sum_{x=1}^I F_\alpha(x)}{I} = \frac{\sum_{i=0}^t z_i u_\alpha}{I} = \frac{(\sum_{i=0}^t z_i)^t u_\alpha}{I}$$

$$F_\alpha(x) = z_i \cdot u_\alpha \quad \text{et} \quad \sum_{i=0}^t z_i = 0 \quad \text{car } Z \text{ est centré}$$

dans

$$\rightarrow \bar{F}_\alpha = 0$$



on fait la somme sur la 1^{ère} var.
sur la 2^{ème} var. = 0 . . .

et on somme donc = 0

$$\frac{\sum_{x=1}^I (F_\alpha(x))^2}{I} = \frac{\| F_\alpha \|_2^2}{I} = \frac{\lambda_1}{I}$$

→ Preuve que la variable F_α est de variance

$$\text{Var}(F_\alpha) = \frac{\sum_{x=1}^I (F_\alpha(x) - \bar{F}_\alpha)^2}{I} = \frac{\sum_{i=0}^t (-F_\alpha(i))^2}{I} = \frac{\| F_\alpha \|_2^2}{I} = \frac{\lambda_1}{I}$$

$$F_\alpha = Z \cdot u_\alpha$$

$$\text{dans } \text{Var}(F_\alpha) = \frac{(Z \cdot u_\alpha)^t (Z \cdot u_\alpha)}{I} = \frac{u_\alpha^t Z^t Z u_\alpha}{I} = \frac{\lambda_1}{I}$$

Fin

→ Le vecteur propre sur lequel la projection est plus étalée, ça veut dire

que la variance est la plus grande la variance qui correspond à $F_{\mu_1} = \frac{\lambda_1}{I}$

et λ_1 est la plus grande valeur propre.

→ μ_2 à la 2^{ème} plus grande variance. $F_{\mu_2} = \frac{\lambda_2}{I}$

Remarque

$$\text{CTR}_\alpha(x) = \frac{(F_\alpha(x))^2}{\lambda_1} \times 100$$

contribution en % de l'individu
($i = 1 \dots I$) à l'inertie λ_1
expliquée par l'axe α .

car $\sum = \lambda_1$

p42:

\Rightarrow les individus projetés sur (μ_1, μ_2)

graphique des individus - graphique des variables

projection des individus.

projection des variables.

Commentaires :

les individus à droite sont caractérisés par les variables à droite.

les individus à gauche sont caractérisés par les variables à gauche.

Si un individu se trouve à côté d'une variable alors il est caractérisé par cette variable

[ex: si on a des étudiants à côté du maths alors ces étudiants sont bons en maths]

les variables à droite caractérisent les régions à droite et ce sont les variables de richesse (PIB/hab, nb de voitures ...)

à gauche ce sont les régions pauvres

les régions à droite sont les régions les plus riches et les régions à gauche sont les plus pauvres.

dans les régions les plus pauvres de la France sont les régions d'Outre-Mer, qui se trouvent pas en France, ce sont des colonies françaises comme la Guyane, la Réunion... régions les plus pauvres car elles sont caractérisées par les variables de pauvreté

les régions ayant un fort PIB sont Languedoc-Roussillon, Rhône-Alpes...

p 43. Formule de transition:

$$\text{pour tout variable } j: G_\alpha(j) = \frac{1}{\sqrt{\lambda_\alpha}} \cdot \sum_{i=1}^I z_i^j F_\alpha(i)$$

$$\text{pour tout variable } i: F_\alpha(i) = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{j=1}^J z_i^j G_\alpha(j)$$

coordonnées des variables en fonction des coordonnées des individus.

" des individus "

variables.

chaque variable se trouve au barycentre de tous les individus, chaque individu est penché par ses variables qui le caractérise par exemple

ses

ceux qui ont bien en maths vont être proches des individus qui ont bien en maths.
Vont être proche des maths.

- une variable se trouve au milieu des individus qui sont forts dans cette variable.
- une matière se trouve au milieu des étudiants forts dans cette matière.
- un individu se trouve au milieu des variables où il est fort.

Voir démo p 44.

Qualité de représentation des individus.

- par exemple on a un individu Z_i et on va le projeter sur un axe α , plus il est proche du plan, mieux il est représenté.
- plus le θ est grand, moins il est représenté.
- si $\pi \theta = \frac{\pi}{2}$ on va tomber dans le centre de gravité.
- plus θ est petit, plus il va être sur l'axe α .

⇒ la qualité de représentation: $CO_2 = \cos^2 \theta$


θ : l'angle qui fait Z_i avec l'axe α , l'angle qui fait l'individu avec l'axe α .

si on est dans un plan:

→ c'est qu'on projette un individu sur le plan et on veut comment il est représenté
→ quelle est sa représentation sur un plan.

→ par ex: est ce qu'un étudiant est bien représenté lorsqu'on le projette sur le plan factoriel.

⇒ c'est l'angle qu'il fait avec le plan. Plus l'angle est petit, plus il est bien représenté



$$QLT_{\alpha, \beta} = \cos^2 \theta = \frac{\|g\|_\alpha^2}{\|g\|_\alpha^2 + \|g\|_\beta^2} = \frac{\|g\|_\alpha^2}{\|g\|_\alpha^2 + \|g\|_\beta^2} = \frac{\|g\|_\alpha^2}{\|g\|_\alpha^2 + \|g\|_\beta^2}$$

qualité de représentation
sur l'axe α et β

$$QLT_{\alpha, \beta} = CO_2_\alpha + CO_2_\beta$$

→ le logiciel Tanagra permet de calculer la qualité de représentation

p 54:

$$\text{pourquoi } Z^j = \sum_a G_a(j) v_a ?$$

$$z^{\delta} = \sum_{\alpha} G_{\alpha}(j) v_{\alpha}$$

c'est la représentation graphique d'une variable quelconque sur l'espace des vecteurs propres dans la base

on a démontré que $v_{\alpha} = \frac{z \cdot u_{\alpha}}{\sqrt{\lambda_{\alpha}}}$

$$v_{\alpha} = \frac{f_{\alpha}}{\sqrt{\lambda_{\alpha}}}$$

dans $z^{\delta} = \sum_{\alpha} G_{\alpha}(j) \cdot \frac{f_{\alpha}}{\sqrt{\lambda_{\alpha}}}$

→ chaque variable peut être exprimée par ses coordonnées sur les axes des individus et ses coordonnées, donc c'est une combinaison linéaire des coordonnées des individus correspondant à cette variable.

→ si on prend la coordonnée $i \rightarrow f_{\alpha}(i)$

Exo :

① vérifier que $z_i = \sum_{\alpha} f_{\alpha}(i) u_{\alpha}$

→ produit scalaire de $z_i u_{\alpha} = \sum_{\alpha} f_{\alpha}(i)$

→ c'est la représentation d'un individu dans la base des vecteurs propres

et $\sum_{\alpha} G_{\alpha}(j) v_{\alpha}$: représentation d'une variable sur la base des vecteurs propres

② montrer que $z = \sum_{\alpha} \sqrt{\lambda_{\alpha}} v_{\alpha} u_{\alpha}^T$ (décomposition en valeurs singulières de z)

b.)

rel.)
rel.

4-)